

POLİFARMASİ YAN ETKİ TAHMİNİ İÇİN HİYERARŞİK GRAF SİNİR AĞI MİMARİSİ

ChemBERTa Transformer + Multi-Head Cross-Attention + Log-Odds Füzyon Raporu | Ağustos 2026

YÖNETİCİ ÖZETİ (EXECUTIVE SUMMARY):

Bu rapor, çoklu ilaç etkileşimlerini (polifarmasi) tahmin etmek amacıyla geliştirilen ve son aşamada ChemBERTa-77M Moleküler Dil Modeli, Çok Başlı Çapraz Dikkat (Multi-Head Cross-Attention) ve Log-Odds Toplamsal Füzyon bileşenleriyle güçlendirilen en gelişmiş yapay zeka mimarisini sunmaktadır. Sistemimiz 2.42 Milyon Biyoaktif Molekül ve 9.61 Milyon Biyolojik Bağlantı ile eğitilmiştir. Model %89.52 Organ Sistemi Doğruluğu, %96.18 Organ AUROC ve %89.04 Spesifik AUROC skorlarına ulaşmıştır.

1. Uygulanan 3 Büyük Mimari Yenilik

- 1. ChemBERTa-77M Transformer Temsilleri: 10 Milyon kimyasal bileşik üzerinde eğitilmiş RoBERTa tabanlı moleküler dil modelinden her ilacın 384 boyutlu yoğun kimyasal zekası çıkarıldı ve toplam nitelik vektörü 3,248 boyuta genişletildi.
- 2. Multi-Head Cross-Attention Mekanizması: İlaç A ve İlaç B arasındaki moleküler çapraz etkileşim çift yönlü dikkat mekanizmasıyla (A attends to B, B attends to A) modellendi. Hangi kimyasal halkaların birbiriyle çakıştığı öğrenildi.
- 3. Log-Odds Toplamsal Füzyon (Additive Fusion): Olasılık çarpımı yerine Log-Odds uzayında toplama yapılarak olasılıkların aşığı büzülmesi engellendi; Seviye 1 organ başarısı doğrudan Seviye 2'ye aktarıldı.

2. Zenginleştirilmiş Veri ve Nitelik Havuzu (3,248 Boyut)

Veri / Nitelik Katmanı	Boyut / Varlık Hacmi	Açıklama & Fonksiyon
ChemBERTa-77M Transformer	384 Boyut	10M molekülden öğrenilmiş derin kimyasal zeka
Morgan (ECFP4) + MACCS	679 Boyut (512 + 167)	Atomik fonksiyonel gruplar ve alt yapılar
RDKit Topological + Descriptors	522 Boyut (512 + 10)	Atom yolları, MW, LogP, TPSA, H-Bağları
Hastalık Endikasyon Vektörü	1,363 Boyut	İlacın tedavi ettiği hastalıklar (BioSNAP)
DTI Protein Hedef Ağı	300 Boyut	İlacın bağlandığı 300 insan hedef proteini
BİRLEŞİK İLAÇ VEKTÖRÜ	3,248 BOYUT	Uçtan Uca Biyomedikal Temsil Matrisi

3. Güncel Model Başarım Raporu ve İterasyon Karşılaştırması

Model Mimarisi	Organ Doğruluk	Organ AUROC	Spesifik AUROC	Spesifik AUPRC	Süre
1. Logistic Regression Baseline	%74.12	%81.40	%76.80	0.4602	~9 dk
2. Standart Decagon GNN	%85.09	%88.71	%86.20	0.5309	25 sn
3. Unified Hierarchical GNN	%89.26	%96.02	%88.52	0.5175	67 sn
4. ChemBERTa + Cross-Attn AI	%89.52	%96.18	%89.04	0.5302	148 sn

4. 2 Seviyeli Karar Mekanizması ve Klinik Simülasyon

SEVİYE 1: ORGAN SİSTEMİ RİSKİ

%89.52 Doğruluk | %96.18 AUROC | 0.9243 AUPRC
15 MedDRA Organ Sistemi: Kalp-Damar, Karaciğer, Mide-Bağırsak, Böbrek, Beyin, Solunum, Kan, Deri, vb.
Doktoru doğrudan tehlikedeki organa odaklar.

SEVİYE 2: SPESİFİK YAN ETKİ TEŞHİSİ

%89.04 AUROC | SIDER 4.1 Priors | P@5: 0.2624
100 Klinik Teşhis: Aritmi, Sarılık, Mide Kanaması, Akut Böbrek Hasarı, Trombositopeni, vb.
Cross-Attention ile çakışan atom halkalarını puanlar.

ÜRETİLEN ARTIFACT VE MODEL DOSYALARI:

- Nihai Model Ağırlıkları: artifacts/champion_chemberta_cross_attention_gnn.pt
- ChemBERTa Nitelik Matrisi: artifacts/drug_features_chemberta.parquet (3,248 Boyut)
- Model Mimarisi: src/models/chemberta_cross_attention_gnn.py | Eğitim: train_chemberta_cross_attention_model.py